

给教授的确认清单

考古学论文插图生成流水线 · v1.1.0

项目	考古学论文插图生成流水线 (arch-illustration-pipeline)
版本	v1.1.0 (提交 39bb615)
需要您	提供 3 项资料 · 拍板 3 项选择 · 给出逐条图意见

6	20	3
待您确认事项	组回归需求	篇待补文献

目录

01 速览：需要您这边的 6 件事

02 需要您提供的资料

03 需要您拍板的选择

04 拉下项目后怎么跑

05 看图提意见怎么写

06 回执表

一、速览：需要您这边的 6 件事

#	事项	为什么需要您	您怎么回	卡住什么
1	20 组历史绘图需求 + 期望命中的文献/页码	这是检索质量的“标尺”：没有它，检索参数一动就没人知道变好还是变坏	表格或文字都行，格式见 §2.1	检索调参、全量入库后的验收
2	3 篇付费文献：Ferrell 1969（纸本 444 页）、Grace 1961 (<i>American Anthropologist</i> 63:359-368, Wiley)、Grace 1964 (<i>Current Anthropology</i> 5:361-368, Chicago)	无合法免费源；需机构订阅或纸本扫描	提供全文 PDF，或告知走什么渠道	这 3 篇进不了知识库
3	13 个坏文件重下 (§2.3 有全名单)	语料体检后实际入库时又检出 11 个新坏文件（下载截断/伪装成 PDF，文件打不开或页数明显不对），加上原先已知的 2 个，共 13 个	重新下载后交给我们	这 13 篇进不了知识库
4	确认 Pawley_Green_Chapter3 的原始目标	疑似即已入库的《The Austronesians》第 3 章（Pawley & Ross），若确认是同一篇就不必再找	是 / 不是（一句话）	避免重复入库或漏一篇
5	服务器内存是多少（只需确认）	早先实测 bge-m3 独占 17.1GB、看着要 ≥32GB； 2026-09-24 复查更正： 那 17GB 是并发缓冲区不是模型，加上限后只要 5GB 、整栈约 8GB → 16GB 就够，不用换模型 (§3.2 有对照表)	告知服务器内存 / 核数即可	机器到位即开跑
6	图内标注方式二选一（见 §3.1）	这是您上次反馈“图里是英文”的正解方向，两种都跑得通，由您定	勾选 A / B，或先看样图	批量出图的默认配置

另外还有一件不是“提供资料”、而是“给意见”的事：对已生成的样图逐条提修改意见 (§5)。这一版专门做了入口，您提的意见会被逐条落实、逐条回执。

二、需要您提供的资料

2.1 二十组历史绘图需求（最重要的一项）

请回想或翻找 20 个真实提过或典型的绘图需求，并为每组写出“期望命中的文献和页码”。格式随意，能对上就行：

#	绘图需求（一句话）	期望命中的文献	期望页码（可留空）
1	绘制二里头文化绿松石龙形器的科学复原图（俯视 45°，白描线图）	《二里头 1999—2006》发掘报告	p.XXX
2			
3			

为什么用这个格式：系统会拿这 20 组去自动跑检索，统计命中率与前几名命中明细。以后凡是动检索、切片、阈值，都先跑它——它是防止我们“越调越差”的**唯一护栏**。页码填不出来就留空，只填文献名也能用。

2.2 三篇付费文献（无合法免费源）

文献	出处	需要什么
Ferrell 1969	纸本，444 页	纸本扫描，或采购
Grace 1961	<i>American Anthropologist</i> 63:359-368 (Wiley 付费墙)	机构订阅下载
Grace 1964	<i>Current Anthropology</i> 5:361-368 (Chicago 付费墙)	机构订阅下载

2.3 十三个坏文件（2026-09-24 全量复查后更新）

原先已知 2 个，入库时又检出 11 个。2026-09-24 对全部 13 个做了**文件头与内容复查**，真实原因分两类——**重下时请特别留意第 2 类**：

- 真截断 2 个：`%PDF-` 开头但只有 0 页（下载中断）；
- 存下来的根本不是 PDF，而是网页 11 个：文件内容以 `<!DOCTYPE html>` 开头，是下载时被重定向到的**出版商页面**——多数是文章落地页（Asia Perspectives 目录页、Europe PMC、Nature 文章页），还有 2 个是 Cloudflare 人机验证页（"Just a moment..."）、1 个 503、1 个 404。也就是说当时**没有登录/没有拿到正文，浏览器把网页存成了 .pdf**。重下时请确认浏览器地址栏是 `.pdf` 直链、文件能打开且页数正常。

全部文件仍在本地 `references/_broken/` 归档，**只移动未删除**。

#	文件名	症状
1	Pawley_Green_Chapter3.pdf	13KB，下载截断
2	Pawley_Prehistory_Oceanic_Languages.pdf	42KB，下载截断
3	[36]_Chang_1970_Ceramic_Style_SE_China.pdf	非有效 PDF
4	[19]_Chang_1970_Prehistoric_Archaeology_Taiwan.pdf	非有效 PDF
5	[18]_Dyen_1963_Malayo-Polynesian_Formosa.pdf	非有效 PDF
6	Skoglund_2016_Nature_Southwest_Pacific.pdf	非有效 PDF
7	Posth_2018_Nature_Ecology_Evolution.pdf	非有效 PDF
8	Hung_2023_SciAdv_Marianas_rice.pdf	非有效 PDF（仅 1 页）
9	Diamond_1988_Nature_Express_train.pdf	非有效 PDF
10	Atkinson_2011_Science.pdf	非有效 PDF（仅 2 页）
11	8_Pawley_Green_1973_Dating_the_Dispersal.pdf	非有效 PDF（仅 1 页）
12	7_Kern_1889-Taalkundige_gegevens_English.pdf	非有效 PDF（仅 1 页）
13	2_Bellwood_1978_Mans_Conquest_of_the_Pacific.pdf	非有效 PDF（仅 2 页）

请重新下载（或从原库重新导出）后交付；其中 #6—#13 多为期刊论文，机构订阅下载时 注意确认文件完整性（能打开、页数正常）。

三、需要您拍板的选择

3.1 图内标注：两种方式二选一

	A. caption_only (当前默认)	B. in_image
图内长什么样	图内不出现任何文字，只用细引线指出标注位置	标注文字写在图上，强制简体中文
名称放哪	图下图注表：编号 名称 图上位置（报告里自动生成，正文可直接用）	图内
学术惯例	考古线图最常见的做法（图内标号、图版说明给名称）	图版中也常见，但依赖模型把中文写对
风险	需正文配图注表	文生图模型渲染中文 不稳定 ：可能出现伪汉字、缺笔，校验会把这类判为不通过并要求重画
校验规则	图内出现任何文字、字母、数字即不通过	出现英文、乱码、不可辨即不通过

建议：由我们各出一版样图（同一需求、同一知识），您对比后勾一个。若选 A 又想在图面上看到编号数字，请一并说明——**默认 A 是连数字也不出现的**（图注表用“图上位置”这一列来描述引线指向哪儿）。

3.2 服务器内存（这一项已经基本有答案了）

早先的实测结论是：嵌入模型 `BAAI/bge-m3` 会独占 **17.1GB** 内存，整栈约 20.5GB，看上去必须换更省内存的嵌入模型、或上 $\geq 32\text{GB}$ 的服务器。

2026-09-24 复查后更正：那 17GB **不是模型本身，而是嵌入服务的并发缓冲区**（默认允许 512 个并发请求、每批 16384 token）。给它加上并发上限之后：

	默认参数	加上限后
嵌入服务常驻内存	17.1 GB	4.98 GB
整个服务栈	约 20.5 GB	约 8.2 GB
入库速度	3–5 页/分钟（还容易因内存不足被系统杀掉）	4.2–6.5 页/分钟

结论：16GB 内存的服务器就能跑，既不必换更小的嵌入模型，也不必非要 32GB。（换模型会让已入库的向量全部作废重算，所以这个更正很关键。）

只差确认一件事：目标服务器实际内存是多少？☐ $\geq 16\text{GB}$ （够用，走默认方案）☐ 更小（我们再评估） 具体：____

3.3 入库排期

215 篇真实语料的全量入库占机器时间较长（实测：论文 3–5 页/分钟，扫描专著约 2.3 页/分钟）。需要您告知：**希望先入哪一部分**（例如先入论文组 165 篇，再入专著 14 本 / 5108 页）。

四、拉下项目后怎么跑

4.1 拉取 (PowerShell)

```
git clone https://github.com/Invinciblesowrder123/arch-illustration-pipeline.git
cd arch-illustration-pipeline
pip install -r requirements.txt
```

- 默认拿到的就是最新主线（含本清单）。已克隆过则 `git pull` 即可。
- 右边栏 **Releases** 页有 v1.1.0 的发布说明（这一版改了什么、怎么用）。
- 若本机没装 git：在仓库页面点 **Code** → **Download ZIP**，解压同样可用。

4.2 填密钥

密钥由我们这边单独提供（仓库里只有 `.env.example` 占位，不含任何真实密钥）。把 `.env.example` 复制为 `.env`，填三处：语言模型 Key、绘图 Key、视觉校验 Key（默认复用语言模型）。

4.3 三条命令

```
python main.py --check --skip-image
python main.py --mode rag
python main.py --revise output/run_xxxx --feedback "您的意见"
```

第一条是自检（连通性 + 环境指纹，零绘图费用）；第二条正式出图（默认最多 3 轮自动重绘）；第三条是看图之后按意见重绘（见 \$5）。

4.4 产物在哪、看什么

路径	看什么
<code>output/run_时间戳/report.md</code>	主报告：知识来源与检索词、引用文献（含页码）、图注表、每轮问题清单与评分
<code>output/run_时间戳/illustration_attempt_N.png</code>	各轮尝试图（最后一张不一定通过）
<code>output/run_时间戳/final_illustration.png</code>	通过校验的成品（没有这个文件 = 没通过）
<code>knowledge/knowledge_summary.md</code>	AI 汇总的绘图知识—— 请重点核对 ：条目是否忠实于文献、页码是否对得上

五、看图提意见怎么写

这一版的意义就在这儿：**您不必改需求从头再来**。写一段话即可，系统会 ①拆成若干条 → ②逐条改 → ③**逐条回执**（改了没有 + 证据在图面哪个位置）。

写法就三件事：

1. **哪一处不对**——尽量指到图面位置（"画面下方居中"比"整体"有用）
2. **应该是什么**——要具体、可判定
3. **哪些地方不许动**——没说的我们也会默认不动，但您明说更稳

好的示例

- 1. 图内标注不要英文，改成中文，写在图外图注表里也行；
- 2. 底部那根比例尺移到右下角，不要压在器物下方；
- 3. 镶嵌片的边界不要画得太规则，现在像砖墙；
- 4. 构图、视角、器物形制不要改。

无效的示例（无法判定，系统只能整段照抄，效果差）

整体还不够准确，再优化一下，风格再学术一点。

一次 2-6 条最佳，每条一行。

六、回执表

6.1 资料类

- ☐ 二十组检索回归集 —— 附件： ____
- ☐ 三篇付费文献 —— 附件： ____
- ☐ 十三个坏文件重下 (§2.3 全名单) —— 附件： ____
- ☐ `Pawley_Green_Chapter3` 是否即《The Austronesians》第 3 章: ☐ 是 ☐ 不是 ☐ 不确定

6.2 选择类

- ☐ 图内标注: ☐ A caption_only ☐ B in_image ☐ 先看样图再定
- ☐ 服务器内存: ☐ $\geq 16\text{GB}$ (够用, 走默认方案) ☐ 更小 (需再评估) 具体: ____
- ☐ 入库顺序: ☐ 先论文组 ☐ 先专著组 ☐ 其他: ____
- 服务器信息 (内存 / 核数) : ____

6.3 意见类

- ☐ 已对样图给出逐条意见 (见附页或邮件)

6.4 其他想说的

(还需要哪些器物、哪些图版 ; 对风格的要求 ; 对报告格式的要求等)

本清单随 v1.1.0 发布。技术细节见仓库内 `README.md` 与 `CHANGELOG.md` ; 开发进展与已知坑见 `docs/DEV_TASKS.md` 与 `docs/HANDOFF.md` 。